Projeto Prático: Apresentação do Algoritmo Naïve Bayes Multinomial para Classificação de Textos e de Sentimentos

PROJETO PRÁTICO (PARTE 1) – Programação Avançada

Eduardo Corrêa Gonçalves

11/03/2026

Sumário

Introdução

Naïve Bayes Multinomial (NB) – uma visão geral

Como se treina um classificador ?

Treinamento do NB – exemplo passo a passo

Classificação com o NB – exemplo passo a passo

Introdução (1/4)

- **O que é Naïve Bayes Multinomial (NB)?**
  - É um **algoritmo** de classificação. Na prática, é usado especialmente para **classificação de texto**.
    - **Isto é**: um algoritmo que, a partir de uma base de dados com textos pré-classificados, produz (ou "aprende") um modelo para classificar novos textos.
  - **Exemplo**: classificador de spam

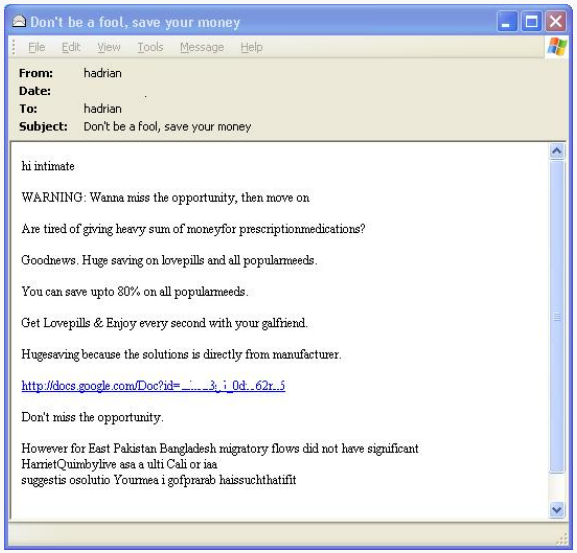

Entrada: **texto do e-mail**

Classificador
(modelo treinado)

{Normal** ou **Spam}

Saída: **uma das classes possíveis**

Introdução (2/4)

- **Algumas aplicações práticas do NB**
  - **(1) Análise de Sentimentos**
    - **Entrada**: texto contendo uma **opinião** sobre um produto, restaurante, filme, candidato etc.
    - **Classes possíveis:** opinião "**positiva**" ou "**negativa**"

"O jantar estava delicioso. Isso sem falar no atendimento impecável." → **Classe: opiniao positiva**

"O risoto do Restaurante XYZ chegou frio e estava super salgado!!! :-(" → **Classe: opiniao negativa**

- Em *alguns problemas*, também existe a classe "**Opiniao neutra**".

Introdução (3/4)

- **Quais as principais aplicações práticas do NB ?**
  - **(2) Identificação de idioma (*language id*)**
    - Processo de identificar automaticamente (classificar) o idioma de um texto.

C'era una volta un piccolo naviglio

C'era una volta un piccolo naviglio
C'era una volta un piccolo naviglio
C'era una volta un piccolo naviglio
che non sapeva, non sapeva navigar.

E pur si mise, si mise a navigar,
E pur si mise, si mise a navigar,
E pur si mise, si mise a navigar,
ma non poté, ma non poté piú navigar.

E dopo una, due, tre, quattro,
Cinque, sei, sette settimane
E dopo una, due, tre, quattro,
Cinque, sei, sette settimane
E dopo una, due, tre, quattro,
Cinque, sei, sette settimane
il naviglio, il naviglio naufragò.

Se questa storia poi non vi dà noia
Se questa storia poi non vi dà noia
Se questa storia poi non vi dà noia
la torneremo torneremo a cominciar.

Classe Italiano

Introdução (4/4)

- **Algumas aplicações práticas do NB**
  - **(3) Atribuição automática de tópicos (*topic tagging*)**
    - Processo de rotular um texto com um ou mais tópicos de acordo com os assuntos por ele abordados.

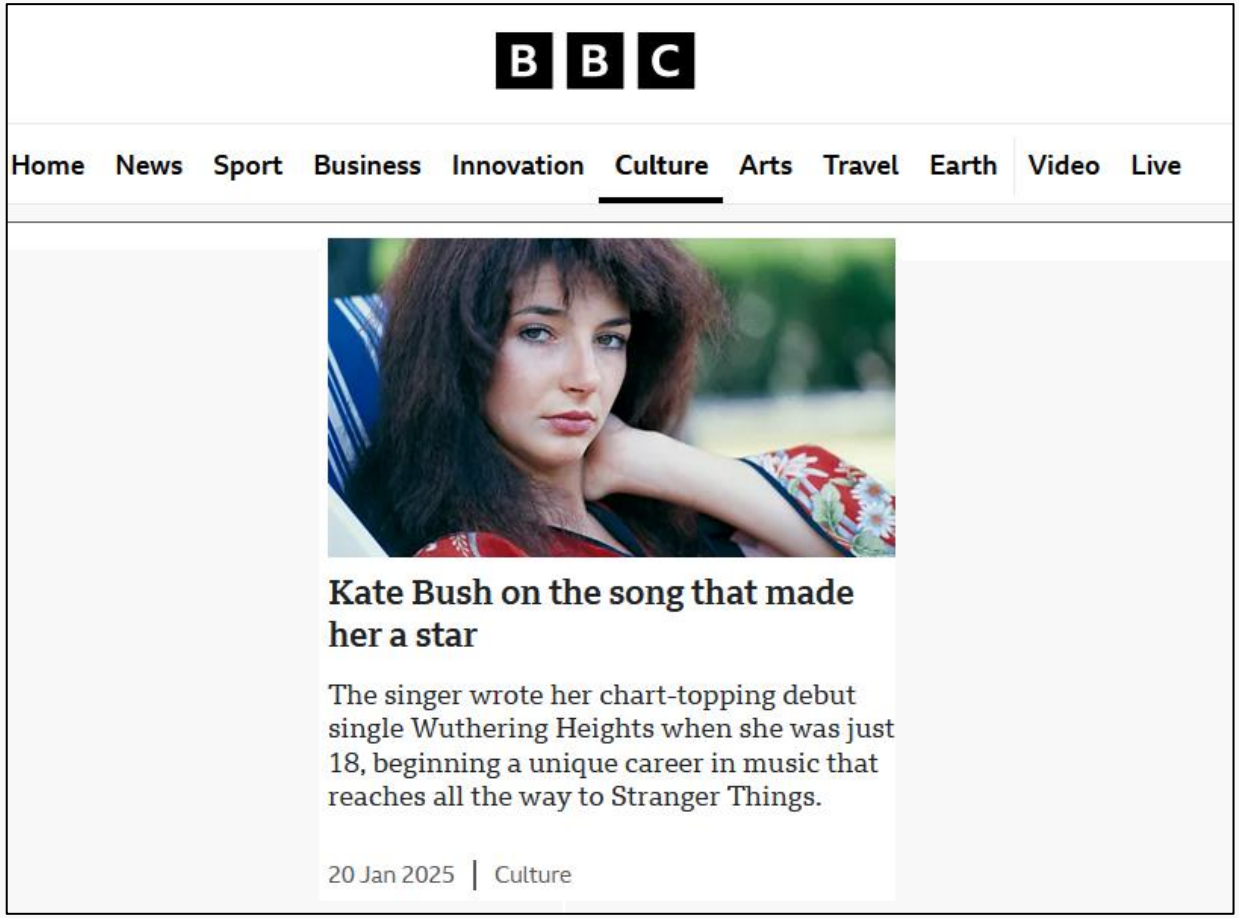

Classe: Cultura

Como criar um classificador ? (1/3)

- Para criar qualquer classificador, você precisa “apenas” de duas coisas:
  - Um bom **algoritmo de classificação**.
    - No nosso caso, o NB
  - Uma boa **base de dados de treinamento**.
    - Esta base deve conter **documentos classificados**, de acordo com **classes pré-definidas**.

** Todos os exemplos foram retirados de Jurafsky e Martin (2026)*

Como criar um classificador ? (2/3)

- **Base de Dados de Treinamento**
  - **Exemplo:** BD para treinar um analisador de sentimentos que classifica a opinião sobre um filme como positiva ou negativa.
    - Contém 5 textos pré-classificados (comentários de 5 pessoas)
      - 3 negativos – **classe** ("-")
      - 2 positivos – **classe** ("+")
    - No jargão da PLN, chamamos um texto de **documento** (mesmo nesse caso onde o texto é um simples comentário).
    - Neste problema, temos $C = \{-, +\}$ (conjunto de classes pré-definidas)

comentário **(documento)**	**sentimento** **(classe)**
just plain boring	-
entirely predictable and lacks energy	-
no surprises and very few laughs	-
very powerful	+
the most fun film of the summer	+

Como criar um classificador ? (3/3)

- **Como todo algoritmo de classificação, o NB tem 2 fases:**
  - **Treinamento**
    - Fase em que o modelo é construído a partir da base de treino.
  - **Classificação**
    - Fase em que o modelo construído na etapa de treinamento é utilizado para classificar um novo documento *d*.
  - *Vamos começar examinando como é o treinamento, depois como funciona a fase de classificação*.

Exemplo Passo a Passo

- **Treinamento e Classificação com o NB**
  - Vamos demonstrar o passo a passo para treinar e utilizar um modelo NB.
  - Faremos com um exemplo hipotético de classificação de sentimentos (Jurafsky e Martin, 2026).
    - Considere a base de dados de treinamento já apresentada anteriormente, contendo comentários de 5 pessoas sobre um filme, sendo 3 negativos ("-") e 2 positivos ("+")

comentário	sentimento (classe)
just plain boring	-
entirely predictable and lacks energy	-
no surprises and very few laughs	-
very powerful	+
the most fun film of the summer	+

Treinamento do Modelo NB (1/3)

- **Passo 1 do treinamento: pré-processamento**
  - Antes de iniciar o treinamento, cada texto precisa ser convertido para uma estrutura chamada *bag of words* (BoW)
    - A BoW de um documento armazena cada palavra e a frequência dela no documento.

comentário	sentimento (classe)
just plain boring	-
entirely predictable and lacks energy	-
no surprises and very few laughs	-
very powerful	+
the most fun film of the summer	+

comentário	sentimento (classe)
{boring: 1, just: 1, plain: 1}	-
{and: 1, energy: 1, entirely: 1, lacks: 1, predictable: 1}	-
{and: 1, few: 1, laughs: 1, no: 1, surprises: 1, very: 1, }	-
{powerful: 1, very: 1}	+
{film: 1, fun: 1, most: 1, of: 1, summer: 1, the: 2}	+

Treinamento do Modelo NB (2/3)

- **Passo 2 do treinamento: geração do modelo**
  - Treinar um modelo NB significa computar uma tabela de frequências em memória.
    - Ela **resume o BD de treinamento**, com as informações sobre a **frequência** com que cada palavra ocorreu dentro dos documentos de cada classe.
    - Essa tabela **é** o modelo NB !!!
  - Veja o resultado no slide a seguir

Treinamento do Modelo NB (3/3)

comentário	sentimento (classe)
{boring: 1, just: 1, plain: 1}	-
{and: 1, energy: 1, entirely: 1, lacks: 1, predictable: 1}	-
{and: 1, few: 1, laughs: 1, no: 1, surprises: 1, very: 1, }	-
{powerful: 1, very: 1}	+
{film: 1, fun: 1, most: 1, of: 1, summer: 1, the: 2}	+

	and	boring	energy	entirely	few	film	fun	just	lacks	laughs	most	no	of	plain	powerful	predictable	summer	surprises	the	very
- (3)	2	1	1	1	1	0	0	1	1	1	0	1	0	1	0	1	0	1	0	1
+ (2)	0	0	0	0	0	1	1	0	0	0	1	0	1	0	1	0	1	0	2	1

Classificação com o Modelo NB (1/8)

- **Classificação de um novo documento *d***
  - O que queremos é que o modelo faça a classificação de um **novo documento** *d* (um texto qualquer contendo uma opinião).
  - No caso do NB, a isso significará estimar a probabilidade do documento *d* composto por *n* palavras f_1, f_2, ..., f_n ser da classe *c* usando a fórmula abaixo:
    - $P(c \mid d) = P(c) \times P(f_1 \mid c) \times P(f_2 \mid c) \times P(f_3 \mid c) \times \ldots \times P(f_n \mid c)$
    - **Obs1**: a fórmula é derivada da Fórmula de Bayes
    - **Obs2**: utilizamos a letra "f" para representar uma palavra, em vez de "p", porque na literatura de IA é comum chamar as variáveis de um problema usando o termo *features*.

Classificação com o Modelo NB (2/8)

- **Classificação de um novo documento *d***
  - É fácil !!!

$$P(c \mid d) = P(c) \times P(f_1 \mid c) \times P(f_2 \mid c) \times P(f_3 \mid c) \times \ldots \times P(f_n \mid c)$$

  - No caso da classificação de sentimentos, devemos estimar as probabilidades de c="+" e c="-", considerando as features do novo doc. *d* a ser classificado (basicamente, a bag of words desse texto).
  - Devemos plugar na fórmula apenas os componentes f_i referentes às **palavras que aparecem no texto** a ser classificado.
    - As demais palavras do vocabulário do problema não precisam ser usadas.

Classificação com o Modelo NB (3/8)

- **Classificação de um novo documento**
  - Seja o novo texto (a ser classificado): *d = "predictable with no fun"*
  - **PASSO 1 da classif.**: transformar esse texto para um bag of words
    - Como o modelo **não conhece a palavra** "**with**" (ela não estava em nenhum dos textos de treinamento), ela vai ser **jogada fora**.
    - *"predictable with no fun"* → {fun: 1, no: 1, predictable: 1}

	and	boring	energy	entirely	few	film	fun	just	lacks	laughs	most	no	of	plain	powerful	predictable	summer	surprises	the	very
- (3)	2	1	1	1	1	0	0	1	1	1	0	1	0	1	0	1	0	1	0	1
+ (2)	0	0	0	0	0	1	1	0	0	0	1	0	1	0	1	0	1	0	2	1

Classificação com o Modelo NB (4/8)

- **<u>PASSO 2 da classificação</u>: correção de Laplace**
  - *"predictable with no fun"* → Veja o modelo! A palavra "fun" nao ocorreu com textos da classe "-" no BD de treinamento
    - Ou seja: $P(c = \text{"-"} \mid \text{fun}) = 0$.
  - Com isso, o valor 0 vai entrar como termo da multiplicação, gerando 0 no resultado da estimativa dessa classe.
  - De maneira análoga, "no" e "predictable" não ocorreram na classe "+".

	and	boring	energy	entirely	few	film	fun	just	lacks	laughs	most	no	of	plain	powerful	predictable	summer	surprises	the	very
- (3)	2	1	1	1	1	0	0	1	1	1	0	1	0	1	0	1	0	1	0	1
+ (2)	0	0	0	0	0	1	1	0	0	0	1	0	1	0	1	0	1	0	2	1

Classificação com o Modelo NB (5/8)

- **<u>PASSO 2 da classificação</u>: correção de Laplace**
  - A solução é realizar a correção de Laplace ao calcular cada $P(c \mid d)$.
  - Isso é feito da seguinte forma. Para qualquer palavra envolvida na classificação:
    - Somamos 1 ao numerador; e
    - 20 ao denominador (pois esse é o tamanho do vocabulário). Veja no slide a seguir.

	and	boring	energy	entirely	few	film	fun	just	lacks	laughs	most	no	of	plain	powerful	predictable	summer	surprises	the	very
- (3)	2	1	1	1	1	0	0	1	1	1	0	1	0	1	0	1	0	1	0	1
+ (2)	0	0	0	0	0	1	1	0	0	0	1	0	1	0	1	0	1	0	2	1

Classificação com o Modelo NB (6/8)

- **<u>PASSO 2 da classificação</u>: correção de Laplace**

$$P(\text{“predictable”}|-) = \frac{1+1}{14+20} \qquad P(\text{“predictable”}|+) = \frac{0+1}{9+20}$$

$$P(\text{“no”}|-) = \frac{1+1}{14+20} \qquad P(\text{“no”}|+) = \frac{0+1}{9+20}$$

$$P(\text{“fun”}|-) = \frac{0+1}{14+20} \qquad P(\text{“fun”}|+) = \frac{1+1}{9+20}$$

	and	boring	energy	entirely	few	film	fun	just	lacks	laughs	most	no	of	plain	powerful	predictable	summer	surprises	the	very
- (3)	2	1	1	1	1	0	0	1	1	1	0	1	0	1	0	1	0	1	0	1
+ (2)	0	0	0	0	0	1	1	0	0	0	1	0	1	0	1	0	1	0	2	1

Classificação com o Modelo NB (7/8)

- **<u>PASSO 3 da classificação</u>: classificando o novo documento**
  - *d = "predictable with no fun"* → {fun: 1, no: 1, predictable: 1}

$$P(-) = \frac{3}{5} \qquad P(+) = \frac{2}{5}$$

$$P(\text{“predictable”}|-) = \frac{1+1}{14+20} \qquad P(\text{“predictable”}|+) = \frac{0+1}{9+20}$$

$$P(\text{“no”}|-) = \frac{1+1}{14+20} \qquad P(\text{“no”}|+) = \frac{0+1}{9+20}$$

$$P(\text{“fun”}|-) = \frac{0+1}{14+20} \qquad P(\text{“fun”}|+) = \frac{1+1}{9+20}$$

Est.1: P(*c* = "-" | *d*)= 3/5 x 2/34 x 2/34 x 1/34 = 6.1 x 10^{-5}

Est.2: P(*c* = "+" | *d*)= 2/5 x 1/29 x 1/29 x 2/29 = 3.2 x 10^{-5}

Classificação com o Modelo NB (8/8)

- **<u>PASSO 3 da classificação</u>: classificando o novo documento**
  - *d = "predictable with no fun"* → {fun: 1, no: 1, predictable: 1}

$$P(-) = \frac{3}{5} \qquad P(+) = \frac{2}{5}$$

$$P(\text{“predictable”}|-) = \frac{1+1}{14+20} \qquad P(\text{“predictable”}|+) = \frac{0+1}{9+20}$$

$$P(\text{“no”}|-) = \frac{1+1}{14+20} \qquad P(\text{“no”}|+) = \frac{0+1}{9+20}$$

$$P(\text{“fun”}|-) = \frac{0+1}{14+20} \qquad P(\text{“fun”}|+) = \frac{1+1}{9+20}$$

Como a estimativa para negativo e maior, o doc e classificado como negativo

Est.1: P(*c* = "-" | *d*)= 3/5 x 2/34 x 2/34 x 1/34 = **6.1 x 10^{-5}**

Est.2: P(*c* = "+" | *d*)= 2/5 x 1/29 x 1/29 x 2/29 = 3.2 x 10^{-5}

Prós e Contras (1/3)

- **NB – Pontos positivos**

☺ **Simplicidade** – o modelo de classificação é apenas uma tabela de frequências.

- Além disso, o algoritmo é fácil de entender e implementar.
- Por isso, é uma boa porta de entrada p/ quem deseja estudar aprendizado de máquina supervisionado.

☺ **Baixo custo computacional** – O treinamento é feito com uma única passada no banco de dados.

- Na hora de classificar um novo texto, só preciso considerar as palavras desse novo texto
- *As outras palavras presentes na tabela gerada pelo modelo podem ser ignoradas*.

☺ **Caixa branca** – Ao contrário dos métodos neurais, é possível identificar o motivo pelo qual uma dada classe foi atribuída a um novo documento.

Prós e Contras (2/3)

- **NB – Pontos negativos**

☹ Em geral, **menos eficaz** que os métodos neurais:

- Porém, funciona surpreendentemente bem em diversos problemas

☹ Pode levar a ocorrência de ***underflow***

- *Mas isso pode ser tratado, como mostra o próximo slide*

☹ **Ignora o conceito** (**semântica**), considera apenas as frequências das palavras para criar o modelo.

Prós e Contras (3/3)

- **Problema**: possibilidade de **underflow**
  - A fórmula do NB para estimar uma classe *c* envolve uma multiplicação de diversos valores de probabilidades.
    - $P(c \mid d) = P(c) \times P(f_1 \mid c) \times P(f_2 \mid c) \times \ldots \times P(f_n \mid c)$
  - Quando muitas variáveis preditivas estão envolvidas no cálculo, pode ocorrer underflow – número muito baixo para ser representado no computador.
- **Solução**: usar a soma dos logaritmos das probabilidades em vez de seus produtos (Jurafsky e Martin, 2026).
    - $\log P(c \mid d) = \log P(c) + \log P(f_1 \mid c) + \log P(f_2 \mid c) + \ldots + \log P(f_n \mid c)\ )$

Referências

- JURAFSKY, D.; MARTIN, J. H. Naive Bayes, Text Classification, and Sentiment. *In*: JURAFSKY, D.; MARTIN, J. H. **Speech and Language Processing**. 3. ed. (Jan. 6, 2026 draft). [*s.l.*] : [*s.n.*], 2026. Appendix B, p. 1-23. Disponível em: https://web.stanford.edu/~jurafsky/slp3/. Acesso em: 24 fev. 2026.